

# Introducción a las redes neuronales: Redes generativas

M. Sc. Saúl Calderón Ramírez  
Instituto Tecnológico de Costa Rica,  
Escuela de Computación, bachillerato en Ingeniería en Computación,  
PAttern Recongition and MACHine Learning Group (PARMA-Group)

29 de mayo de 2019

## Resumen

Este material está basado en el capítulo de redes generativas, del libro *Deep Learning* de Ian Goodfellow et. al[1].

## 1 Teoría de juegos y modelos conexionistas

Las redes generativas combinan ingeniosamente la **teoría de juegos** (rama de las probabilidades) con los **modelos conexionistas** o redes neuronales, originalmente propuestas en el artículo *Generative Adversarial Nets*, GoodFellow et. al, 2014. Los autores proponen el siguiente escenario de juego: Un agente **generador** de muestras sintéticas

$$\vec{x}_k = g(\vec{z}, \vec{w}^g)$$

debe competir contra un agente **adversario o discriminador**

$$\tilde{p}_j = d(\vec{x}_j, \vec{w}^d)$$

donde:

- $g$  es el modelo correspondiente al **generador de muestras**, según lo propuesto por los autores, una red neuronal con parámetros a ajustar  $\vec{w}^g$  y entrada  $\vec{z}$ , la cual corresponde a una generadora de entropía con una distribución específica, la cual le permite al modelo generar las muestras con tal distribución. La salida del modelo consiste entonces en la muestra artificial o falsa  $\vec{x}_k^f$  para la cual sabemos no es real, lo que se representa en la etiqueta  $r_k = 0$ .
- $d$  corresponde al modelo **adversario o discriminador** con parámetros  $\vec{w}^d$  (también una red neuronal según los autores), el cual tiene por objetivo

estimar la probabilidad  $\tilde{p}_j$  de que la muestra  $\vec{x}_j$  sea real, representado en la **etiqueta de veracidad**  $r_j = 1$  cuando es real, y  $r_j = 0$  de otro modo. Basado en ello, podemos construir una función de densidad binomial

$$p(\vec{x}_j, r_j) = (1 - \tilde{p}_j)^{1-r_j} \tilde{p}_j^{r_j}$$

la cual describe la probabilidad de que la muestra  $\vec{x}_j$  sea real o artificial. Para un conjunto de muestras  $X = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N\}$  y sus respectivo conjunto de etiquetas de veracidad  $R = \{r_1, \dots, r_N\}$ . El discriminador buscará entonces maximizar al siguiente función de verosimilitud:

$$P(X|R) = \prod_{i=1}^N p(\vec{x}_i, r_i) \quad (1)$$

para  $r_i \in R$  y  $\vec{x}_i \in X$ .

El objetivo del agente generador de muestras es generar las muestras lo más reales posibles, para **engañar** al agente discriminador, mientras que por el contrario, el agente discriminador tiene por meta **discriminar** de la forma más acertada entre las muestras creadas por el agente generador y las muestras reales representadas en la matriz

$$X^r = \begin{bmatrix} | & | & | & | \\ \vec{x}_1^r & \vec{x}_2^r & \dots & \vec{x}_N^r \\ | & | & | & | \end{bmatrix} \quad R^r = [1 \dots 1_N],$$

con su correspondiente matriz de veracidad  $R^r$ .

Lo anterior se expresa en lo que los autores llaman un juego de suma nula, con la función  $v(g, d)$  la cual determina la **recompensa** al discriminador. Entre **más alta la recompensa, mejor trabajo estará haciendo el discriminador** en adivinar qué muestras son artificiales o son reales (y por ende, pertenecen al conjunto de muestras  $X$ ). El objetivo entonces del **generador al ser engañar al discriminador, es entonces disminuir la recompensa al discriminador**, lo cual se expresa entonces en el siguiente problema de minimización/maximización:

$$\arg \min_g \max_d v(g, d)$$

Existen muchas formas de elegir la función de recompensa al discriminador, una de ellas es utilizando el **logaritmo de la función de verosimilitud, para un conjunto de muestras**  $X = [X^r, X^f]$  y sus respectivas etiquetas de veracidad  $R = [R^r, R^f]$ , donde la matriz

$$X^f = \begin{bmatrix} | & | & | & | \\ \vec{x}_1^f & \vec{x}_2^f & \dots & \vec{x}_N^f \\ | & | & | & | \end{bmatrix}$$

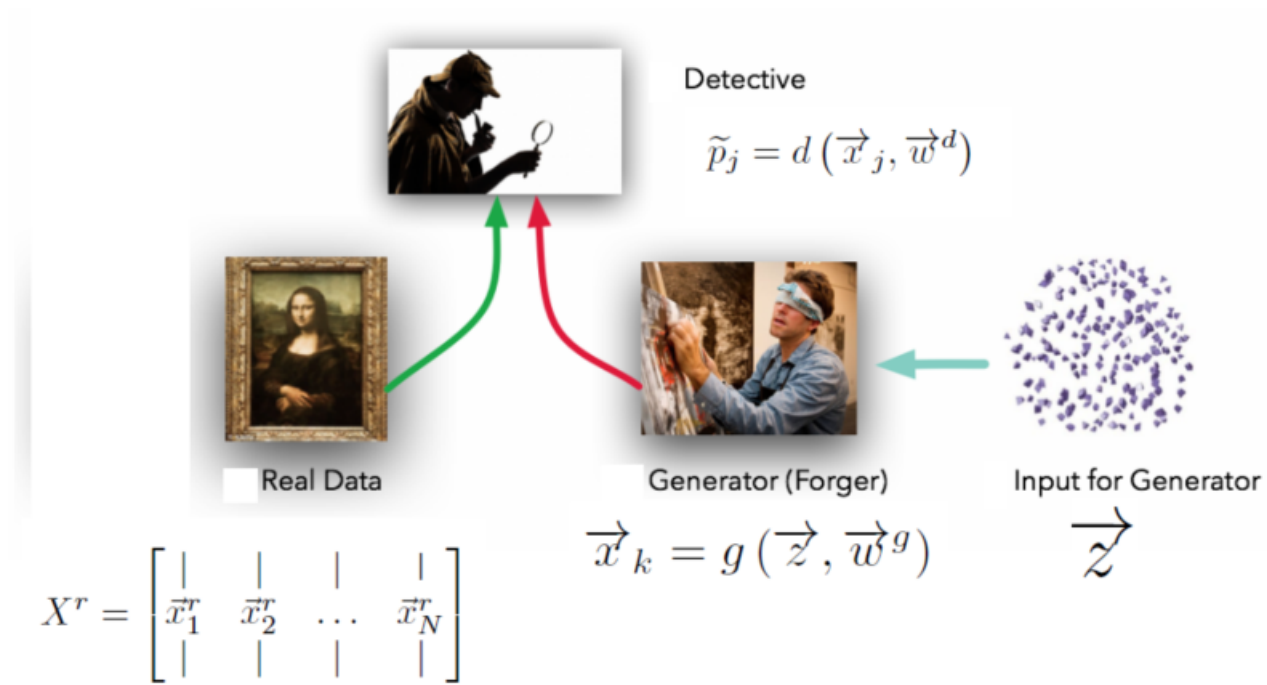


Figura 1: Aprendizaje adversario generativo. Tomado de <https://bit.ly/2tttFZtv>.

contiene muestras construidas por el generador por lo que  $\vec{x}_k^f = g(\vec{z}, \vec{w}^g)$  y  $R^f = [0 \dots 0_N]$ . Tal logaritmo de la función de verosimilitud se basa entonces en la Ecuación 1:

$$v(g, d) = \log(P(X|R)) = \sum_{i=1}^N \log\left((1 - \tilde{p}_j)^{1-r_j} \tilde{p}_j^{r_j}\right)$$

$$\Rightarrow v(g, d) = \frac{1}{N} \sum_{i=1}^N (1 - r_j) \log(1 - d(\vec{x}_i, \vec{w}^d)) + r_j \log(d(\vec{x}_i, \vec{w}^d))$$

La Figura 1 ilustra el concepto de aprendizaje adversario generativo.

## Referencias

- [1] Christopher M Bishop. *Pattern recognition and machine learning*. springer, 2006.